
如何微调 BERT 用于文本分类

Sun Chi

上海市智能信息处理重点实验室

计算机科学系

复旦大学

中国上海

sunc17@fudan.edu.cn

Xu Yige

上海市智能信息处理重点实验室

计算机科学系

复旦大学

中国上海

xpqiufudan.edu.cn

Huang Xuanjing

上海市智能信息处理重点实验室

计算机科学系

复旦大学

中国上海

xjhuang@fudan.edu.cn

摘要: 语言模型预训练被证明对于学习通用语言表征有效。作为一个 SOTA(State-of-the-Art, 最厉害的) 预训练语言模型, BERT(Bidirectional Encoder Representations from Transformers) 在很多语言理解任务上取得了令人惊叹的结果。在本文中, 我们做了全面的实验来调查文本分类任务下不同微调 BERT 的方法, 提供了一个通用的 BERT 微调解决方案。最后, 提出的解决方案在八个广泛研究的文本分类数据集上取得了新的 SOTA 结果。

关键词: 迁移学习; BERT; 文本分类

1 导言

文本分类是自然语言处理 (NLP, Natural Language Processing) 里一个经典的问题。这个任务是为给定的文本序列分配预先定义类别。一个重要的中间步骤是文本的表示。之前的工作使用不同的神经网络模型来学习文本的表征, 包括卷积神经网络模型、循环神经网络模型和注意力机制。

最近, 预训练语言模型通过利用大量的无标注数据, 在学习通用语言表征上显得很有用: 例如 ELMo[1]、OpenAI GPT[2] 和 BERT[3]。他们当中, BERT 是基于一个多层的、双向的 Transformer[4], 并且以掩码预测和下一个句子预测为任务在纯文本上训练。

尽管 BERT 在许多自然语言理解 (NLU, Natural Language Understanding) 任务上取得了令人惊叹的结果, 他的潜力仍然未被完全探索。几乎没有研究是加强 BERT 来进一步提升在下游任务的表现的。在本文中, 我们研究了如何最大化 BERT 用于文本分类的效果。我们探索了几个微调 BERT 以提升其在文本分类任务上性能的方式。我们设计了全面的实验, 只为做出 BERT 的详尽分析。

本文的贡献如下:

- 我们提出了一个通用的解决方案，用于微调预训练 BERT 模型，包括三个步骤：(1) 进一步利用任务内训练数据或同领域数据对 BERT 进行预训练；(2) 若有若干相关任务，可选地采用多任务学习对 BERT 进行微调；(3) 针对目标任务对 BERT 进行微调。
- 我们还研究了针对目标任务对 BERT 进行微调的方法，包括逐层学习率、灾难性遗忘以及少样本学习等问题。
- 我们在八个广受研究的文本分类数据集上取得了新的 SOTA 成果。

2 相关工作

在自然语言处理领域，借助从其他任务上习得的知识正日益收到关注。我们简洁地综述了两个相关方法：语言模型预训练和多任务学习。

2.1 语言模型预训练

预训练的词嵌入 [5, 6]，作为现代自然语言处理系统的重要组成部分，比从零开始学习的词嵌入有更显著的提升。词嵌入的泛化形式，比如句子嵌入 [7, 8] 或者段落嵌入 [9]，同样被用作下游任务的特征。

Peters 等人 [1] 将从语言模型得来的词嵌入拼接作为主任务的额外特征，这在若干自然语言处理基准测试中刷新了 SOTA 效果。除了用无监督数据进行预训练外，使用大量的监督数据进行迁移学习也能取得良好的性能，比如自然语言推理 [10] 和机器翻译 [11]。

最近，使用大量无标注数据在一个巨大的神经网络上预训练语言模型，然后在下游任务上微调的方法在若干自然语言理解任务上取得了突破，比如 OpenAI GPT[2] 和 BERT[3]。Dai 和 Le[12] 使用语言模型微调的方法，但即便用了 10000 个样本仍然出现了过拟合。而 Howard 和 Ruder[13] 提出了 ULMFiT 方法并在文本分类任务上取得了 SOTA 效果。BERT 在一个大型的跨领域语料上以掩码语言模型任务和下一个句子预测任务建模。不同于以往仅由两个单向语言模型（即从左到右与从右到左）简单组合而成的双向语言模型（biLM），BERT 使用掩码语言模型来预测随机被掩盖或者替换的词元。BERT 是首个基于微调的表征模型，在多项自然语言处理任务上均取得了 SOTA 效果，证明了微调方法的巨大潜力。本文中，我们进一步探索了微调 BERT 用于文本分类。

2.2 多任务学习

多任务学习 [14, 15] 是另一个相关的方向。Rei[16] 和 Liu 等人 [17] 使用这个方法联合训练语言模型和主任务模型。Liu 等人 [18] 通过复用 BERT 的编码器作为共享文本编码层，拓展了最初在 [19] 提出的 MT-DNN 模型。多任务学习要求每次都从头开始训练任务，因此不够高效且通常要求仔细加权每个任务的目标函数 [20]。然而，我们可以使用多任务 BERT 微调，通过充分利用其共享预训练权重来避免这个问题。

3 用于文本分类的 BERT

BERT-base 模型包含一个具有 12 个 Transformer 块的编码器，每个 Transformer 块有 12 个自注意力头，隐藏状态维度为 768。BERT 接收不超过 512 个词元长度的序列输入并输出这个序列的表征。输入序列有一个或两个子节，第一个词元总是 [CLS]，它蕴含着特殊的分类嵌入。另一个特殊的词元是 [SEP]，用来分割子节。

对于文本分类任务，BERT 取出第一个词元 [CLS] 的最后一个隐藏状态 h 作为整个序列的表示。接着在 BERT 顶部加入一个简单的 softmax 分类头来预测标签 c 的概率：

$$p(c|h) = \text{softmax}(Wh) \quad (1)$$

W 是任务特定的参数矩阵。我们通过最大化正确类标号的对数似然来将 BERT 的所有参数和 W 一起微调。

4 方法论

当我们将 BERT 适配到目标领域的自然语言处理任务时，我们需要一个合适的微调策略。在本文中，我们通过一下三个方式寻找合适的微调方法。




图 1: BERT 微调的三种通用方式（用不同颜色表示）。(彩色图见在线版本)

(1) **微调策略**：当我们针对某个目标任务对 BERT 进行微调时，可以有多种方式利用 BERT。例如，BERT 的不同层能够捕获不同层次的语义和句法信息，那么哪一层更适合目标任务？此外，我们该如何选择更合适的优化算法和学习率？

(2) **进一步预训练**：BERT 在与目标领域有着不同数据分布的通用领域上训练。一个自然的想法是在目标领域数据上进一步预训练 BERT。

(3) **多任务微调**：在没有预训练语言模型的情况下，多任务学习已经证明了其在利用多个任务之间共享知识方面的有效性。当在目标领域中存在多个可用任务时，一个有趣的问题是：同时所有任务上对 BERT 进行微调是否仍然能够带来收益。

我们微调 BERT 的总体策略在图1中展示。

4.1 微调策略

神经网络的不同层可以捕获不同层级的语义和句法信息 [13, 21]。

为了将 BERT 适配到一个目标任务，我们需要考虑过拟合问题。我们需要一个有着恰当学习率的更好的优化器。凭直觉来说，BERT 模型的更低层可能蕴含更一般的信息。我们可以用不同的学习率来微调他们。

参照 [13]，我们将参数 θ 拆分为 $\{\theta^1, \dots, \theta^L\}$ ， θ^l 包含 BERT 第 l 层的参数。然后参数依照如下方法更新：

$$\theta_t^l = \theta_{t-1}^l - \eta^l \cdot \nabla_{\theta^l} J(\theta) \quad (2)$$

η^l 代表第 l 层的学习率。

我们设基准学习率为 η^L 并使用 $\eta^{k-1} = \xi \cdot \eta^k$, 其中 ξ 是一个衰退因子并且小于等于 1。当 $\xi < 1$, 更低的层比更高的层有更小的学习率。当 $\xi = 1$, 所有层有相同的学习率, 这相当于常规的随机梯度下降。我们将在第5.3节探讨这些因子。

4.2 进一步预训练

BERT 模型在通用领域语料上预训练。对于某个具体领域的文本分类任务, 比如电影评论, 它的数据分布可能与 BERT 的不同。因此, 我们可以用掩码语言模型和下一个句子预测任务在具体领域数据上继续预训练 BERT。我们实施了三个进一步预训练方法:

- (1) 任务内预训练, BERT 在某个目标任务的训练数据集上进一步预训练。
- (2) 领域内预训练, 预训练数据从某个目标任务的相同领域获得。例如, 有若干不同的情感分类任务, 但他们的数据分布相同。我们可以结合这些任务的训练数据来进一步预训练 BERT。
- (3) 跨领域预训练, 预训练数据从某个目标任务的同一或者不同领域获得。

我们将在第5.4节研究这些不同的进一步预训练方法。

4.3 多任务微调

多任务学习也是一个共享从若干相关监督任务获取的知识的有效方法。类似 [18], 我们也在多任务学习框架下微调了 BERT, 用于文本分类。

所有任务共享 BERT 层和嵌入层。唯一不共享的层是最后的分类头层, 这意味着每一个任务都有自己的分类头。实验分析见第5.5节。

表 1: 八个文本分类数据集的统计数据

Dataset	Classes	Type	Average lengths	Max lengths	Train samples	Test samples
IMDb [22]	2	Sentiment	292	3,045	25,000	25,000
Yelp P. [23]	2	Sentiment	177	2,066	560,000	38,000
Yelp F. [23]	5	Sentiment	179	2,342	650,000	50,000
TREC [24]	6	Question	11	39	5,452	500
Yahoo! Answers [23]	10	Question	131	4,018	1,400,000	60,000
AG's News [23]	4	Topic	44	221	120,000	7,600
DBPedia [23]	14	Topic	67	3,841	560,000	70,000
Sogou News [23]	6	Topic	737	47,988	54,000	6,000

5 实验

我们在七个英文文本分类任务和一个中文文本分类任务上对不同的微调方法进行了探究。实验采用基础版 BERT 模型: 分别为不区分大小写的 BERT-base 模型以及中文 BERT-base 模型。

5.1 数据集

我们在八个广泛研究的经典数据集上对本文方法进行了评估。这些数据集的文档数量与文本长度各不相同, 涵盖了三类常见的文本分类任务: 情感分析、问题分类和主题分类。各数据集的统计信息如表1所示。




图 2: 灾难性遗忘

数据预处理。仿照 [3], 我们使用具有 30000 个词元大小的词汇表的 WordPiece 词嵌入 [25], 并使用 ## 标记拆分后的词片。因此, 数据集中文档长度的统计结果均基于词片 (word pieces) 计算。在对 BERT 进行进一步预训练时, 我们使用 spaCy 工具对英文数据集执行分句处理; 而在处理中文搜狗新闻数据集时, 则以 “。” “?” 和 “!” 作为分隔符进行分句。

5.2 超参数

我们使用具有 768 维隐藏大小、12 个 Transformer 块 [4]、12 个自注意力头的 BERT-base 模型 [3]。我们在 1 个 TITAN Xp GPU 上进一步预训练了 BERT, 批量大小为 32, 最大序列长度为 128, 学习率为 $5e-5$, 训练步数为 100000 并且预热步数为 10000。

我们在 4 个 TITAN Xp GPU 上微调了 BERT, 设置批量大小为 24 来保证 GPU 显存被充分利用。丢弃率 (Dropout Rate) 一直保持在 0.1。我们使用 Adam 优化器, 设置 $\beta_1 = 0.9$ 和 $\beta_2 = 0.999$ 。我们使用了倾斜三角学习率 [13], 基准学习率为 $2e-5$, 预热比例为 0.1。我们以经验为依据, 设置最大轮数 (epoch) 为 4 并且把在验证集上最好的模型保存下来用于测试。

5.3 实验一: 研究不同微调策略

在本节中, 我们使用 IMDb 数据集来研究不同的微调策略。我们加载官方的预训练模型作为初始编码器。

逐层递减的学习率。表2展示了不同基准学习率和衰退因子 (见方程2) 在 IMDb 数据集上的表现。我们发现给更低的层使用更低的学习率对于微调 BERT 有效, 并且恰当的配置是 $\xi = 0.95$ 和 $lr = 2.0e-5$ 。

灾难性遗忘。灾难性遗忘 [26] 是在迁移学习中的一个常见现象, 这意味着在学习新知识的过程中, 预训练的知识被抹去了。因此, 我们也研究了 BERT 是否会遭受灾难性遗忘问题。

我们用不同学习率微调了 BERT, IMBd 数据集上的错误率学习曲线在图2中展示。

表 2: Decreasing layer-wise layer rate.

Learning rate	Decay factor ξ	Test error rates (%)
2.5e-5	1.00	5.52
2.5e-5	0.95	5.46
2.5e-5	0.90	5.44
2.0e-5	1.00	5.42
2.0e-5	0.95	5.40
2.0e-5	0.90	5.52

Domain	Sentiment			Question		Topic	
Dataset	IMDb	Yelp P.	Yelp F.	TREC	Yah. A.	AG's News	DBPedia
IMDb	4.37	2.18	29.60	2.60	22.39	5.24	0.68
Yelp P.	5.24	1.92	29.37	2.00	22.38	5.14	0.65
Yelp F.	5.18	1.94	29.42	2.40	22.33	5.43	0.65
All sentiment	4.88	1.87	29.25	3.00	22.35	5.34	0.67
TREC	5.65	2.09	29.35	3.20	22.17	5.12	0.66
Yah. A.	5.52	2.08	29.31	1.80	22.38	5.16	0.67
All question	5.68	2.14	29.52	2.20	21.86	5.21	0.68
AG's News	5.97	2.15	29.38	2.00	22.32	4.80	0.68
DBPedia	5.80	2.13	29.47	2.60	22.30	5.13	0.68
All topic	5.85	2.20	29.68	2.60	22.28	4.88	0.65
All	5.18	1.97	29.20	2.80	21.94	5.08	0.67
W/o pretrain	5.40	2.28	30.06	2.80	22.42	5.25	0.71

表 3: Cross-domain performance results




图 3: 不同增量预训练步骤在 IMDb 数据集上的效果。BERT-ITPT-FiT 表示 “BERT + 任务内预训练 + 微调”。

我们发现更低的学习率，比如 $2e-5$ ，对于使 BERT 战胜灾难性遗忘问题是必要的。如果设置 $4e-4$ 的激进学习率，训练集将不能收敛。

5.4 实验二：研究进一步预训练

除了使用监督学习微调 BERT，我们可以使用掩码语言建模和下一个句子预测任务在训练数据上进一步预训练 BERT。在本节中，我们研究了进一步预训练的有效性。在接下来的实验中，我们将在微调阶段使用在实验一中得出的最优策略。

任务内进一步预训练。因此，我们首先研究了任务内进一步预训练的有效性。我们采用经过不同步数进一步预训练的模型，然后在文本分类任务上对其进行微调。

正如图3所示，进一步预训练对于提高 BERT 在某一个目标任务上的性能是有用的，这里是在 10 万 (100K) 步后取得了最佳性能。

领域内和跨领域进一步预训练除了某个目标任务的训练数据，我们还可以用相同领域的数据来进一步预训练 BERT。在本小节中，我们研究了使用领域内和跨领域的数据是否能继续提升 BERT 的性能。

我们把七个英语数据集分成了三个领域：话题、情感和问题。划分方式不一定严格正确。因此我们还做了跨任务预训练的拓展实验，实验中每个任务都被视作一个不同的领域。

结果展示在表3。我们发现几乎所有进一步预训练的模型都在所有七个数据集上表现的比原来的 BERT-base 模型更好。一般地，领域内预训练可以带来比任务来预训练更好的性能。在小规模句子级 TREC 数据集上，任务内预训练会损害模型性能；而利用 Yah. A. 语料的领域内预训练，则能在 TREC 数据集上取得更好效果。

与之前模型的对比。我们把我们的模型与基于特征的迁移学习方法（例如区域嵌入 [27] 和 CoVe[11]）和当时文本分类 SOTA 的语言模型微调方法 (ULMFiT)[13] 进行了比较。

我们把 BERT 模型的特征用作带有自注意力 [28] 的双向长短期记忆网络 (biLSTM) 的输入嵌入，做出了 BERT-Feat。BERT-IDPT-FiT 的结果对应表3的”all sentiment” ”allquestion” 和”all topic” 行，BERT-CDPT-FiT 对应”all” 行。如表4所示，BERT-Feat 比除了 ULMFiT 的其他所有基线表现的更好。除了比 BERT-Feat 在 DBpedia 数据集稍微差一点，BERT-FiT 在其他七个数据集上超过了 BERT-Feat。此外，所有三个进一步预训练模型都比 BERT-FiT 模型好。以 BERT-Feat 为参考，我们计算了其他 BERT-FiT 模型在每个数据集上的平均百分比提升。BERT-IDPT-FiT 表现最好，平均降低了 18.57% 的错误率。

Model	IMDb	Yelp P.	Yelp F.	TREC	Yah. A.	AG	DBP	Sogou	Avg. Δ
Region Emb. [27]	/	3.60	35.10	/	26.30	7.20	1.10	2.40	/
CoVe [11]	8.20	/	/	4.20	/	/	/	/	/
ULMFiT [13]	4.60	2.16	29.98	3.60	/	5.01	0.80	/	/
BERT-Feat	6.79	2.39	30.47	4.20	22.72	5.92	0.70	2.50	-
BERT-FiT	5.40	2.28	30.06	2.80	22.42	5.25	0.71	2.43	9.22%
BERT-ITPT-FiT	4.37	1.92	29.42	3.20	22.38	4.80	0.68	1.93	16.07%
BERT-IDPT-FiT	4.88	1.87	29.25	2.20	21.86	4.88	0.65	/	18.57%
BERT-CDPT-FiT	5.18	1.97	29.20	2.80	21.94	5.08	0.67	/	14.38%

表 4: 八个文本分类数据集上的测试错误率 (%)：BERT-Feat 指 “BERT 作为特征提取器”，BERT-FiT 指 “BERT + 微调”，BERT-ITPT-FiT 指 “BERT + 任务内预训练 + 微调”，BERT-IDPT-FiT 指 “BERT + 领域内预训练 + 微调”，BERT-CDPT-FiT 指 “BERT + 跨领域预训练 + 微调”。

5.5 实验三：多任务微调

当存在若干用于文本分类任务的数据集时，为了充分利用这些数据，我们进一步考虑了一个多任务的微调步骤。我们用四个英语文本分类数据集 (IMDb, Yelp P., AG, 和 DBP)。Yelp F. 数据集被排除在外，因为它的测试集与 Yelp P. 的训练集有重叠，此外，两个问题领域的数据集也被排除了。

表 5: 多任务微调的测试错误率

Method	IMDb	Yelp P.	AG	DBP
BERT-FiT	5.40	2.28	5.25	0.71
BERT-MFiT-FiT	5.36	2.19	5.20	0.68
BERT-CDPT-FiT	5.18	1.97	5.08	0.67
BERT-CDPT-MFiT-FiT	4.96	2.06	5.13	0.67




图 4: IMbd 数据集上的少样本文本分类

表5表明对于基于 BERT 的多任务微调, 效果改善了。然而, 多任务微调似乎对 BERT-CDPT 在 Yelp P. 和 AG. 数据上并没有帮助。多任务微调 and 跨领域预训练可能是互为替代的方法, 因为 BERT-CDPT 模型已经蕴涵了丰富的领域信息, 而多任务学习可能对提升相关文本分类子任务的泛化性并不必要。

5.6 实验四：少样本文本分类

预训练模型的好处之一就是可以使用少量训练数据来为下游任务训练一个模型。我们在不同数量训练样本上评估了 BERT-Fit 和 BERT-ITPT-Fit。我们选择了 IMdb 训练数据的一个子集并把它喂给 BERT-Fit 和 BERT-ITPT-Fit。我们把结果展示在图4了。

表 6: 五个文本分类数据集上的错误率 (%)

Model	IMdb	Yelp P.	Yelp F.	AG	DBP
ULMFiT	4.60	2.16	29.98	5.01	0.80
BERT _{BASE}	5.40	2.28	30.06	5.25	0.71
+ ITPT	4.37	1.92	29.42	4.80	0.68
BERT _{LARGE}	4.86	2.04	29.25	4.86	0.62
+ ITPT	4.21	1.81	28.62	4.66	0.61

5.7 实验五：BERT-Large 上的进一步预训练

在这个子节中, 我们将研究 $BERT_{LARGE}$ 模型是否与 $BERT_{BASE}$ 模型具有类似结果。我们用一个 Tesla-V100-PCIE 32G GPU 进一步预训练了谷歌的预训练 $BERT_{LARGE}$, 批量大小为 24, 最大序列长度为 128, 12 万个训练步数。对于目标任务分类头的 BERT 微调, 我们设置批量大小为 24 然后在 4 个 Tesla-V100-PCIE 32G GPU 微调了 $BERT_{LARGE}$, 最大序列长度为 512。

如表6所示, ULMFiT 几乎在所有的任务上比 $BERT_{BASE}$ 表现更好, 但比不过 $BERT_{LARGE}$ 。而在针对任务的进一步预训练后, 情况发生了变化: 即便使用 BERT-BASE, 也能在所有任务上超越 ULMFiT。针对任务的进一步预训练 $BERT_{LARGE}$ 经过微调取得了 SOTA 结果。

6 结论

在本文中，我们实施了大范围的实验来研究不同针对文本分类的 BERT 微调方法。有一些实验结果：(1) 有了适合的逐层衰减学习率，BERT 可以克服灾难性遗忘问题；(2) 任务内和领域内的进一步预训练可以显著提高性能；(3) 预先的多任务微调也有助于单一任务的微调，但其好处比进一步预训练小；(4) 经过进一步预训练的 BERT 在少样本文本分类中表现良好。

有了以上的结果，我们在八个广受研究的文本分类数据集上取得了 SOTA 性能。在未来，我们会探索更多 BERT 的运行机制。

鸣谢

本研究工作得到国家重点研发计划项目（编号：2018YFC0831103）资助。

参考文献

- [1] Matthew E. Peters et al. Deep contextualized word representations. arXiv preprint arXiv:1802.05365, 2018.
- [2] Alec Radford, Karthik Narasimhan, Tim Salimans, and Ilya Sutskever. Improving language understanding by generative pre-training. <https://s3-us-west-2.amazonaws.com/openai-assets/research-covers/languageunsupervised/languageunderstandingpaper.pdf>, 2018.
- [3] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. Bert: Pre-training of deep bidirectional transformers for language understanding. arXiv preprint arXiv:1810.04805, 2018.
- [4] Ashish Vaswani et al. Attention is all you need. In Advances in Neural Information Processing Systems, pages 5998–6008, 2017.
- [5] Tomas Mikolov, Ilya Sutskever, Kai Chen, Greg Corrado, and Jeffrey Dean. Distributed representations of words and phrases and their compositionality. In Advances in Neural Information Processing Systems, pages 3111–3119, 2013.
- [6] Jeffrey Pennington, Richard Socher, and Christopher Manning. Glove: Global vectors for word representation. In Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing, pages 1532–1543, 2014.
- [7] Ryan Kiros et al. Skip-thought vectors. In Advances in Neural Information Processing Systems, pages 3294–3302, 2015.
- [8] Lajanugen Logeswaran and Honglak Lee. An efficient framework for learning sentence representations. arXiv preprint arXiv:1803.02893, 2018.
- [9] Quoc Le and Tomas Mikolov. Distributed representations of sentences and documents. In International Conference on Machine Learning, pages 1188–1196, 2014.

- [10] Alexis Conneau, Douwe Kiela, Holger Schwenk, Loïc Barrault, and Antoine Bordes. Supervised learning of universal sentence representations from natural language inference data. arXiv preprint arXiv:1705.02364, 2017.
- [11] Bryan McCann, James Bradbury, Caiming Xiong, and Richard Socher. Learned in translation: Contextualized word vectors. In *Advances in Neural Information Processing Systems*, pages 6294–6305, 2017.
- [12] Andrew M. Dai and Quoc V. Le. Semi-supervised sequence learning. In *Advances in Neural Information Processing Systems*, pages 3079–3087, 2015.
- [13] Jeremy Howard and Sebastian Ruder. Universal language model fine-tuning for text classification. arXiv preprint arXiv:1801.06146, 2018.
- [14] Rich Caruana. Multitask learning: A knowledge-based source of inductive bias. In *Proceedings of the Tenth International Conference on Machine Learning*, 1993.
- [15] Ronan Collobert and Jason Weston. A unified architecture for natural language processing: Deep neural networks with multitask learning. In *Proceedings of the 25th International Conference on Machine Learning*, pages 160–167. ACM, 2008.
- [16] Marek Rei. Semi-supervised multitask learning for sequence labeling. arXiv preprint arXiv:1704.07156, 2017.
- [17] L. Liu et al. Empower sequence labeling with task-aware neural language model. In *Proceedings of the Thirty-Second AAAI Conference on Artificial Intelligence*, 2018.
- [18] Xiao Liu, Pengcheng He, Weizhu Chen, and Jianfeng Gao. Multi-task deep neural networks for natural language understanding. arXiv preprint arXiv:1901.11504, 2019.
- [19] Xiao Liu, Jianfeng Gao, Xiaodong He, Deng Li, Kevin Duh, and Ye-Yi Wang. Representation learning using multi-task deep neural networks for semantic classification and information retrieval. 2015.
- [20] Zhao Chen, Vijay Badrinarayanan, Chen-Yu Lee, and Andrew Rabinovich. Gradnorm: Gradient normalization for adaptive loss balancing in deep multitask networks. arXiv preprint arXiv:1711.02257, 2017.
- [21] Jason Yosinski, Jeff Clune, Yoshua Bengio, and Hod Lipson. How transferable are features in deep neural networks? In *Advances in Neural Information Processing Systems*, pages 3320–3328, 2014.
- [22] Andrew L. Maas, Raymond E. Daly, Peter T. Pham, Dan Huang, Andrew Y. Ng, and Christopher Potts. Learning word vectors for sentiment analysis. In *Proceedings of the 49th Annual Meeting of the Association for Computational Linguistics: Human Language Technologies*, pages 142–150, 2011.
- [23] Xiang Zhang, Junbo Zhao, and Yann LeCun. Character-level convolutional networks for text classification. In *Advances in Neural Information Processing Systems*, pages 649–657, 2015.
- [24] Ellen M. Voorhees and Dawn M. Tice. The trec-8 question answering track evaluation. In *TREC*, volume 1999, page 82, 1999.

- [25] Yonghui Wu et al. Google’s neural machine translation system: Bridging the gap between human and machine translation. arXiv preprint arXiv:1609.08144, 2016.
- [26] Michael McCloskey and Neal J. Cohen. Catastrophic interference in connectionist networks: The sequential learning problem. In *Psychology of Learning and Motivation*, volume 24, pages 109–165. Elsevier, 1989.
- [27] Chengwei Qiao et al. A new method of region embedding for text classification. In *International Conference on Learning Representations*, 2018.
- [28] Zhouhan Lin et al. A structured self-attentive sentence embedding. arXiv preprint arXiv:1703.03130, 2017.